Documentazione progetto Ingegneria della Conoscenza 2021-2022

Indice

Introduzione

Questo progetto è stato realizzato per l'esame di Ingegneria della Conoscenza dagli studenti Serio Luca (matricola 716494) e Nasca Raffaella (matricola 718752).
Abbiamo trattato un dominio attuale in questi ultimi anni quale il Covid.
Il nostro sistema è in grado di prevedere se si è positivi al virus SARS-CoV-2 a seconda dei sintomi analizzati dal dataset preso in considerazione e inoltre è in grado di consigliare all'utente se rivolgersi ad uno specialista, spiegheremo meglio più avanti.

Requisiti Funzionali

I requisiti funzionali sono relativamente pochi.
Avendo progettato il programma in Python, si richiede un ambiente in grado di eseguire codice come Eclipse, Intellij…
Relativamente alle librerie esterne importate, vediamo la necessità di installare sulla macchina:

- **pandas**, usato per la manipolazione e l'analisi dei dati;
- **scikit-learn**, per applicare i concetti del Machine Learning;
- **numpy**, per lavorare con array multidimensionali e applicare specifiche operazioni logiche/matematiche;
- **pytholog**, per utilizzare la programmazione logica in Python.

Ognuna delle quali può essere installata dal CLI di windows con il comando:
"python -m pip install nome_libreria"

Manuale utente

E' possibile scaricare il progetto dal seguente link https://github.com/luca1701/ICON .
Dopo averlo scaricato si dovrà eseguire il file "prediction" su un IDE.

```
Benvenuto nel sistema per predire se sei affetto dal virus SARS-CoV-2
    Per capire cio' vi faremo una serie di domande su patologie pregresse e sintomi che potreste avere
    Vi preghiamo di rispondere con la massima sincerita'
    Grazie

Le risposte devono essere date nei possibili seguenti modi:
    ->si-s-yes-y
    ->no-n
Hai problemi di respirazione?
```

Questo rappresenta la schermata iniziale una volta avviato correttamente il programma, presenta una breve descrizione e poi iniziano le domande necessarie ad effettuare la predizione.

Qui di fianco troviamo appunto le domande richieste, che verranno richieste sequenzialmente.
In particolare in questa foto si è presentato uno dei casi in cui il sistema consiglia la visita specialistica a causa dei sintomi comunicati.

```
Hai problemi di respirazione?
si
Hai febbre?
n
Hai tosse secca?
si
Hai mal di gola?
no
Hai asma?
si
Hai malattia del cuore?
no
Hai diabete?
no
Hai ipertensione?
si
Hai viaggiato all'estero?
no
Hai avuto contatti con pazienti COVID?
no
Hai partecipato ad un grande raduno?
n
Hai visitato posti esposti al pubblico?
s
La tua famiglia lavora in luoghi esposti al pubblico?
n
Si consiglia la visita da uno specialista!

Secondo le prestazioni del sistema e le risposta date, l'utente non e'
affetto da Covid-19
```

Scelte progettuali

Abbiamo utilizzato il dataset dal seguente link: [Symptoms and COVID Presence (May 2020 data) | Kaggle] per addestrare il nostro sistema.
I modelli e le tecniche utilizzate:

- prima di passare direttamente all'apprendimento supervisionato abbiamo osservato il dataset scelto, e mediante una matrice di correlazione abbiamo notato alcune features che risultavano poco coerenti/discriminanti nei confronti della feature obiettivo e pertanto abbiamo effettuato *features selection*, passando da questa prima situazione

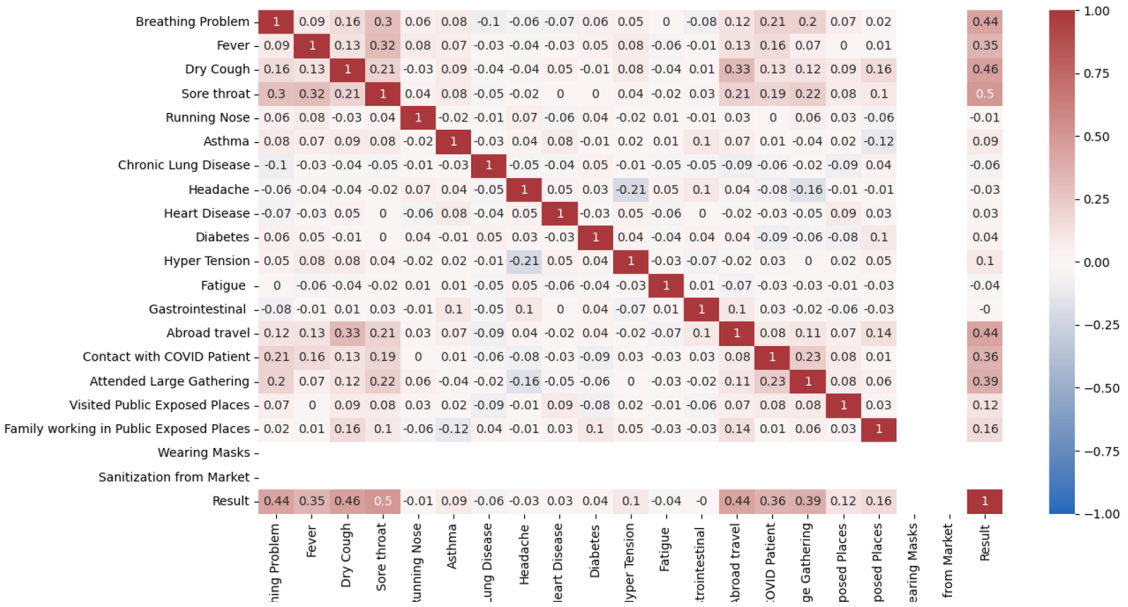

a quest'altra

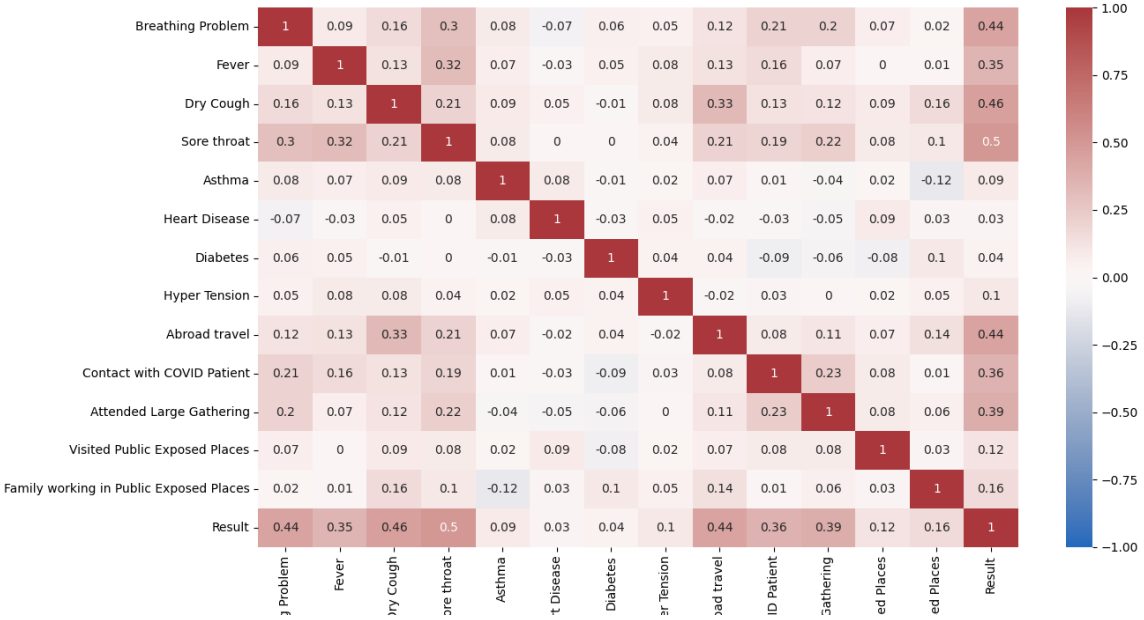


```
data = pd.read_csv(r".\..\dataset\usable.csv")
```

```
data=data.drop('Wearing Masks',axis=1)
data=data.drop('Sanitization from Market',axis=1)
data=data.drop('Running Nose',axis=1)
data=data.drop('Chronic Lung Disease',axis=1)
data=data.drop('Headache',axis=1)
data=data.drop('Fatigue ',axis=1)
data=data.drop('Gastrointestinal ',axis=1)

data.to_csv(r".\..\dataset\usable.csv", index=False)
```

calcolando accuratezza del sistema prima e dopo l'eliminazione delle features abbiamo notato una leggera

diminuzione della precisione (circa 0.02), ma che abbiamo pensato fosse accettabile, all'ulteriore fine di non stancare l'eventuale utente durante l'interazione e quindi ricevere risposte reali e non date a caso.
Per plottare la matrice di correlazione, abbiamo usato un metodo di Pandas, in particolare *pandas.Dataframe.corr()*, e come metrica di correlazione Pearson.

- abbiamo utilizzato un albero decisionale come classificatore, per la predizione della feature obiettivo.
  Questa scelta non è stata casuale ma ci siamo basati sui seguenti dati che mostrano l'accuratezza riscontrata in 5 esecuzioni del sistema, ognuna delle quali utilizzando una K-Fold cross validation, mostra la media riscontrata tra le precisioni calcolate nelle varie convalide, *deviation* indica la deviazione standard:

Model	K-Fold	Deviation
DecisionTree Classifier	0,998100	0,001
DecisionTree Classifier	0,998085	0,001
DecisionTree Classifier	0,998232	0,000
DecisionTree Classifier	0,998224	0,001
DecisionTree Classifier	0,998169	0,001
Media	0,998162	0,001
KNeighborsClassifier	0,946329	0,001
KNeighborsClassifier	0,942096	0,001
KNeighborsClassifier	0,940061	0,002
KNeighborsClassifier	0,945248	0,002
KNeighborsClassifier	0,943285	0,002
Media	0,943404	0,001
Naive Bayes	0,991677	0,005
Naive Bayes	0,991738	0,002
Naive Bayes	0,991681	0,002
Naive Bayes	0,991951	0,003
Naive Bayes	0,991633	0,003
Media	0,991736	0,003

GradientBoostingClassifier	0,997600	0,001
GradientBoostingClassifier	0,997553	0,001
GradientBoostingClassifier	0,997414	0,001
GradientBoostingClassifier	0,997347	0,002
GradientBoostingClassifier	0,997683	0,001
Media	0,997519	0,001
RandomForestClassifier	0,998026	0,001000
RandomForestClassifier	0,998103	0,001000
RandomForestClassifier	0,998300	0,001000
RandomForestClassifier	0,997290	0,001000
RandomForestClassifier	0,998264	0,000000
Media	0,997997	0,001

Questo classificatore è stato scelto a causa delle alte prestazioni rispetto agli altri e non abbiamo preso affatto in considerazione i regressori a causa del contenuto del dataset, che contiene soli valori discreti, in particolare binari.
Il file di cui è stato mostrato l'estratto è disponibile nel repository fornito, al seguente percorso 'test_models', del quale di seguito un breve confronto

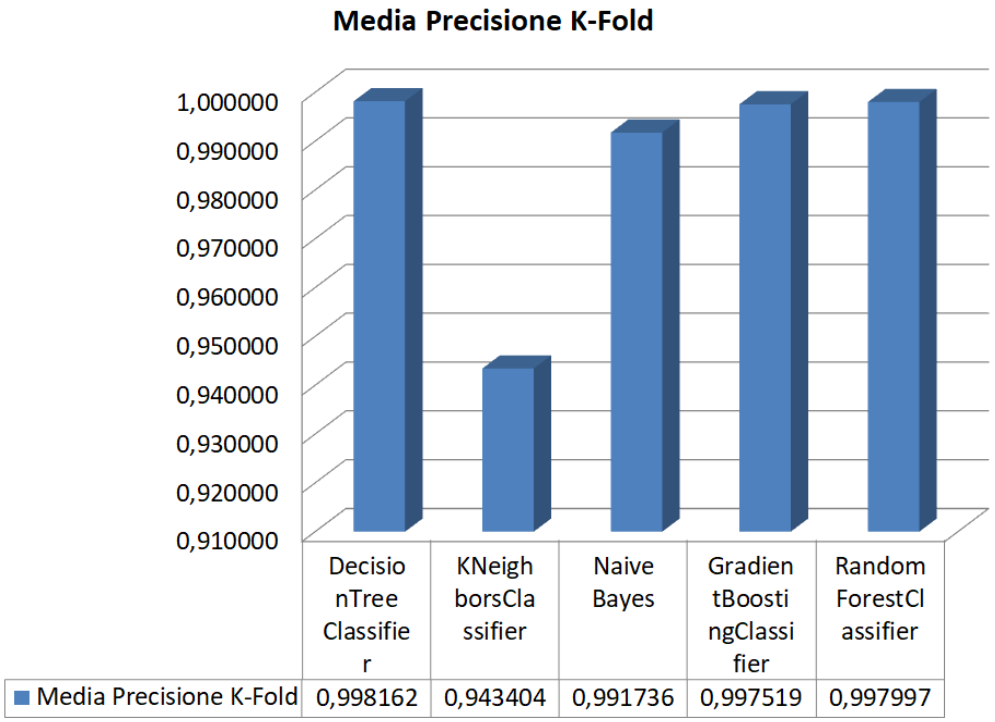

- Come strumento per misurare l'accuratezza del sistema, ci siamo avvalsi della K-Fold cross-validation. In particolare usavamo 10 fold e come metrica per l'accuratezza la "Compute Area Under the Receiver Operating Characteristic Curve" (roc_auc), abbiamo scelto questa a causa della sua compatibilità con features binarie.
  Abbiamo implementato anche una funzione che permette di visionare la precisione del sistema, nell'esecuzione corrente. Anche qui come metrica per le precisione abbiamo la *roc_auc*, che utilizza di default una macro-media.
- cosi come per l'accuratezza, abbiamo pensato potesse tornare utile tenere conto dell'errore che il sistema presenta, quindi sempre mediante un'apposita funzione, è possibile osservare il "Mean Absolute Error", cioè l'errore assoluto riscontrato tra le features predette e quelle reali sia in fase di training che di test.
  Es: del Decision Tree Regressor;

```
Accuracy
L'accuratezza sulle predizioni fatte in fase di apprendimento e' di 0.998462794307433
L'accuratezza sulle predizioni fatte in fase di test e' di 0.9992479197781097

Mean Absolute Error
MAE train 0.02362294538408
MAE test 0.017940603129195588
```

- ci siamo poi voluti cimentare con il prolog, effettuando una semplice KB, composta da asserzioni che specificano la manifestazione, o meno, di specifici sintomi comunicati dall'utente, cosi da consigliare di andare da uno specialista per una visita più approfondita, ciò a prescindere dalla predizione effettuata dal sistema. In particolare viene consigliata una visita se l'utente comunica di avere *asma*, *problemi respiratori* e *tosse secca* o *bruciore di gola*, il chè potrebbe potenzialmente manifestare una complicazione del quadro clinico del paziente, sempre relativamente

al covid. Per fare ciò abbiamo inserito in una KB , 2 proposizioni: *symp* e *several*. La prima permette di asserire la presenza del sintomo, a seconda delle risposte dell'utente, la seconda verrà utilizzata in fase di interrogazione, in particolare restituirà valore vero in due possibili casi:

a. l'utente ha dichiarato di avere asma, problemi respiratori e tosse secca;
b. l'utente ha dichiarato di avere asma, problemi respiratori e bruciore di gola;

```
kb([f"symp(asma,{ris[0][4].lower()})",
    f"symp(breathproblem,{ris[0][0].lower()})",
    f"symp(sorethroat,{ris[0][3].lower()})",
    f"symp(drycough,{ris[0][2].lower()})",
    "several(S) :- symp(asma, S), symp(breathproblem, S), symp(drycough, S)",
    "several(S) :- symp(asma, S), symp(breathproblem, S), symp(sorethroat, S)",
    ])
```

Architettura del sistema

Il sistema presenta la seguente struttura:

- *esame*
  - *dataset*, contenente i dataset utilizzati. In particolare, *covid_symptoms* è quello originale, cioè così come reperito da Internet, che abbiamo pensato fosse bene conservare, e il secondo *usable* che rappresenta il dataset effettivamente utilizzato in fase di apprendimento;
  - *src*, contenente tutto il codice sorgente.
    - *model_performance.py*, contiene le funzioni utili a osservare le prestazioni del sistema (accuratezza, K-Fold e l'errore assoluto). Per quanto riguarda queste funzioni, abbiamo deciso di implementarle, non renderle utilizzabili all'utente ma conservarle per applicazioni/modifiche future, in cui possano tornare utili.
    - *prediction.py*, costituisce il cuore del progetto, si occupa di richiamare le librerie necessarie, aprire il dataset, creare un modello, addestrare il sistema e in seguito al richiamo dei metodi necessari all'acquisizione dei sintomi dell'utente, effettuare la predizione vera e propria.
    - *prolog.py*, contiene la base di conoscenza che include i sintomi più gravi che possono suggerire una visita da uno specialista
    - *questions.py*, contiene la parte di interazione con l'utente in cui vengono poste una serie di domande;
    - *user.py*, una classe con metodi e attributi necessari ad asserire i sintomi comunicati dall'utente;

Implementazioni future

Avremmo voluto implementare altre funzionalità in modo da migliorarlo ancora, ma a causa delle limitate conoscenze pratiche, ci siamo dovuti fermare.
In particolare avremmo voluto implementare la funzionalità per cui una volta ottenuta la predizione, se pari ad 1, quindi potenzialmente positiva al covid, chiedendo la nazione di

residenza, avremmo voluto predire la variante del virus, utilizzando un dataset trovato in rete fornito da un ente autorevole e pertanto affidabile.
Oltre questo saremmo stati interessati a prevedere una data indicativa, relativa all'assenza di casi Covid-19, per il mondo intero sarebbe difficile, avremmo potuto considerare una singola nazione, osservando dataset sui casi giornalieri e dataset sulle vaccinazioni.

Processo e sviluppo dell'organizzazione del lavoro

Il nostro progetto è stato svolto sull'IDE *Eclipse*, abbiamo collaborato attraverso la piattaforma *Microsoft Teams* nel caso di problemi relativi a scelte implementative o codice e usato *github* come piattaforma di code hosting.

Conclusioni

É stato un progetto che ci ha fatto impegnare tanto, sia per la limitata conoscenza del linguaggio utilizzato, migliorata nel corso della progettazione stessa, che per l'applicazione dei concetti studiati durante il corso. Tutto sommato siamo soddisfatti del risultato raggiunto e ci piacerebbe tornare ad approfondire o applicare alcune delle implementazioni future citate sopra.